

Analyzer 三类任务分桶策略

Code · Text2SQL · General Text

Code	Text2SQL	General Text
输出契约、语法、接口、语义、边界与效率	SQL 契约、语法、Schema、语义、类型与效率	指令、相关性、事实、推理、完整性、表达与安全

核心目标

把评测中观察到的失败转化为可执行的数据补充计划。错误频率只是需求信号，最终训练比例还会结合归因置信度、严重程度、迁移价值、学习效率和数据成本。

本文档简要说明 Analyzer 当前对 Code、Text2SQL 和 General Text 三类任务的失败样本分桶与训练数据分配策略。

1. 共同原则

01 三条路线独立分桶：Code、Text2SQL 和 General Text

使用不同的能力桶，不把不同任务的错误混在一起统计。

02 错误占比不等于训练占比：错误数量只表示缺陷被观察到的频率，训练投入还要考虑归因置信度、严重程度、迁移价值、学习效率和数据成本。

03 优先重分类 [other](#)：先利用执行日志、评测标签和错误原因把 [other](#) 归入具体能力桶；仍无法归因的样本进入“待诊断样本”，训练预算为 0。

04 保留探索预算：如果大量样本在前置环节失败，后续能力实际上没有被充分测试，系统会给被遮蔽的能力保留少量探索数据。

05 小规模试训后动态更新：首轮使用学习效率先验；后续按“目标指标增量 / 新增样本数”更新学习效率，再调整下一轮比例。

每个桶的基础权重为：

$$\text{weight}_i = \text{error_share}_i^{\alpha} * \text{confidence}_i * \text{severity}_i * \text{transfer}_i * \text{learnability}_i / \text{data_cost}_i$$

权重归一化后得到建议训练比例。当前默认 [alpha=1.0](#)，单个有效桶的建议比例通常限制在 5% 至 50%，避免单一错误完全挤占训练数据。

2. Code 分桶

能力桶	典型问题	推荐数据方向
代码补全输出契约	输出解释、Markdown 围栏、缺少完整函数	函数签名或 Docstring 到完整可执行代码的严格格式样本
Python 语法与补全完整性	缩进、括号、字符串、 <code>return</code> 或函数体不完整	短小 Python 语法修复与代码补全样本
函数接口、作用域与依赖	函数名或签名错误、变量未定义、缺少导入	接口保持、局部变量、标准库和辅助函数样本
语义逻辑与断言正确性	代码可执行但结果错误	带正常断言和反例断言的短算法样本
边界条件与鲁棒性	空输入、单元素、重复值、极值处理错误	边界条件与对比样本
运行时与效率	超时、递归过深、复杂度退化	低效与高效实现的成对优化样本

当“代码补全输出契约”占失败样本 50% 以上时，系统仍会为语法、接口和语义能力保留探索预算，避免因为代码尚不可执行就误判这些能力没有问题。

3. Text2SQL 分桶

能力桶	典型问题	推荐数据方向
SQL 输出契约	输出解释、Markdown 或不可直接执行的 SQL	问题与 Schema 到纯 SQL 的严格输出样本
SQL 语法与结构	SELECT、JOIN、聚合、子查询结构错误	短 SQL 修复与结构化组合样本
Schema Linking	表、列、实体或外键匹配错误	问题实体与 Schema 显式对齐、易混 Schema 对比样本
SQL 语义与结果正确性	SQL 可执行但过滤、聚合、排序或去重错误	可执行但结果错误的查询纠正样本
类型、值与条件表达	日期、数值、NULL、字符串和类型转换错误	值匹配、条件表达和类型边界样本
SQL 运行时与效率	查询超时或不必要的高复杂度	等价 SQL 的低效与高效实现对比样本

当“SQL 输出契约”占失败样本 50% 以上时，系统会额外探索 SQL 语法、Schema Linking 和语义正确性，避免前置格式错误遮蔽真实查询能力。

4. General Text 分桶

能力桶	典型问题	推荐数据方向
指令与输出格式遵循	未满足格式、长度、结构或显式约束	多约束指令遵循和可验证格式样本
相关性与意图理解	答非所问、偏离用户目标、误解意图	相似意图辨析和目标对齐样本
事实性与知识依据	事实错误、幻觉、缺少给定依据	有可信来源或给定上下文的事实核验样本
推理与一致性	推理跳步、因果错误、前后矛盾	多步推理、一致性检查和反例验证样本
完整性与要点覆盖	漏答关键点、回答截断、信息不足	按评分要点补全和覆盖关键信息的样本
表达与语言质量	不流畅、不连贯、冗余或语法较差	流畅性、简洁性和结构化表达的改写样本
安全与拒答边界	应拒绝未拒绝，或对正常请求过度拒绝	合理拒答、不必要拒答和安全替代回答样本

General Text 优先使用 Judger 提供的结构化标签和理由归因；仅在证据明确时使用空回答、格式违规或明显拒答等规则回退。普通 exact-match 失败不会被强行猜测为某个能力桶，而是进入待诊断样本。

General Text 采用两级统计：先确定上述能力桶的训练比例，再在每个能力桶内部统计领域分布，例如知识问答、摘要、写作或对话，避免把“领域”和“能力缺陷”混为一类。

5. 输出与使用

分桶结果写入：

```
state["analyzer"]["allocation_plan"]
```

报告中会同时给出：原始错误占比、重分类结果、建议训练比例、样本构造方向、代表性失败案例和待诊断样本告警。该比例适合作为下一轮数据补充的初始方案，不应被视为固定不变的长期数据配方。

6. 参考方法

- HELM (TMLR 2023)：将通用能力拆为正确性、鲁棒性与安全性等维度。
- InstructGPT (NeurIPS 2022)：将指令遵循和用户意图对齐作为独立能力。
- TruthfulQA (ACL 2022)：区分事实性问题与表面文本相似度。
- Skill-It! (NeurIPS 2023)：考虑能力之间的先后依赖和被遮蔽能力的探索。
- DoReMi (NeurIPS 2023)：根据训练价值动态优化数据混合，而非固定按频率分配。
- LESS (ICML 2024)：使用目标任务收益选择更有影响力的训练数据。